

Primer Trabajo Estadística II

Inferencia Estadística

Integrantes:

1. Johan Santiago Rojas Naranjo - 2225005
2. Brainer David Lopez Muñoz - 2225505
3. Diego Andres Barragan Ruiz - 2211827

- Fuente de los datos (url):

<https://microdatos.dane.gov.co/index.php/catalog/853/get-microdata>

- Descripción de los datos seleccionados:

La **Gran Encuesta Integrada de Hogares (GEIH) 2025**, realizada por el Departamento Administrativo Nacional de Estadística (DANE) en Colombia, es una encuesta nacional por muestreo que recopila información sobre las características demográficas, educativas y económicas de la población, con énfasis en el mercado laboral; sus datos permiten medir indicadores como la tasa de desempleo, ocupación, informalidad e ingresos, así como analizar las condiciones de los hogares y apoyar la formulación de políticas públicas basadas en evidencia.

- Variables seleccionadas:

Variables Cualitativas		
Nombre Variable		Categorías o Niveles
1	tipo_hogar	1.Casa 2.Apartamento 3.Cuarto(s) 4.Vivienda Indígena 5.Otra vivienda

Variables Cuantitativas		
Nombre Variable		Unidad de medición
1	Ingresos_hogar	Pesos
2	promedio_edad	Unidades
3	valor_arriendo	Pesos

Desarrollo

Valor del arriendo:

- *Análisis Descriptivo*

Descriptivos Básicos

	Medida	Valor
1	Número de hogares	29.104
2	Mínimo	180.000
3	Máximo	12.000.000

	Medida	Valor
1	Número de hogares	29.104
2	Mínimo	180.000
4	Media	665.201
5	Mediana	550.000
6	Moda	500.000
7	Rango	11.820.000
8	Desviación Estándar	500.894
9	Coeficiente de variación	75.3%


Comentarios:

En esta sección se divide a la población en 2 partes quienes pagan arriendo y quienes no una vez hecho esto usamos la parte de personas que sí pagaban arriendo y se establecieron unos límites en estos valores ya que se presentaban datos de 98 y 450.000.000 valores poco razonables y que no van de la mano con la situación de Colombia en el 2025 estos límites fueron de 180.000 y 12.000.000 algo más acorde a la situación una vez hecho esto se presentaron los resultados obtenidos en la tabla anterior.

Análisis Gráfico

Boxplot del valor mensual del arriendo

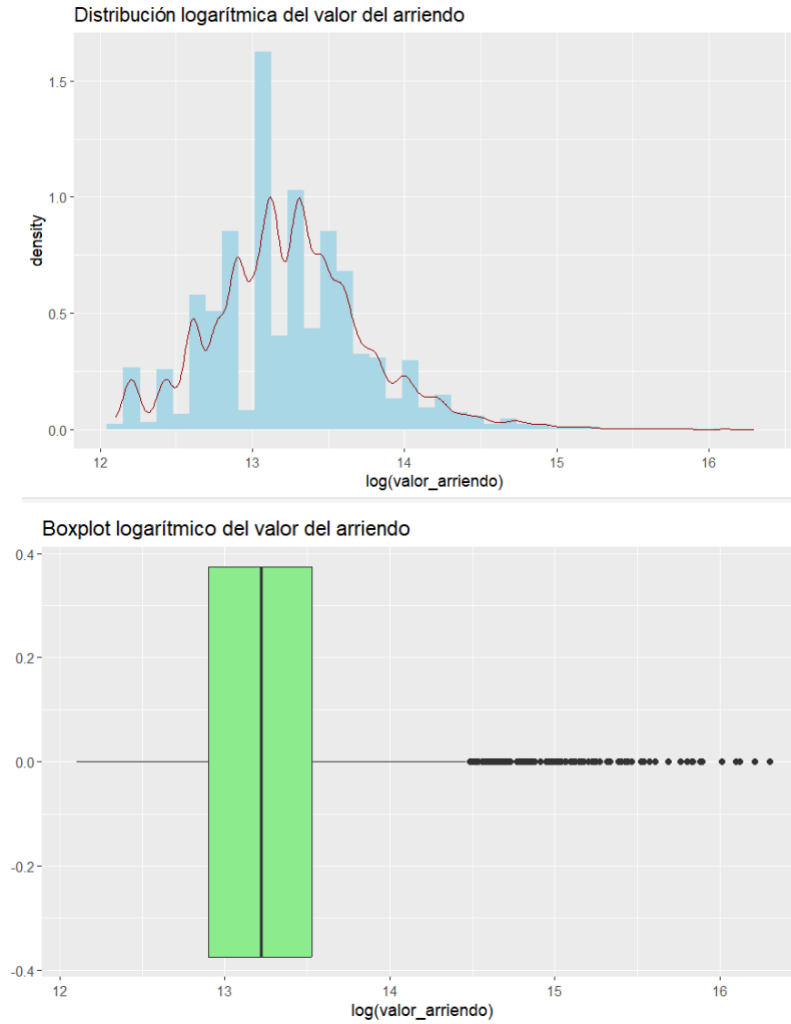
Mediana, rango intercuartílico y valores atípicos



Distribución del valor mensual del arriendo

Hogares que pagan arriendo





Comentarios:

En las gráficas originales del **valor mensual del arriendo** se observa una **distribución fuertemente asimétrica a la derecha** (sesgo positivo). El histograma muestra que la mayoría de los hogares se concentran en valores bajos y medios (alrededor de 500.000–700.000), mientras que existe una cola larga hacia valores altos, lo que indica la presencia de **valores atípicos** significativos (arriendos muy elevados). Esto se confirma con el boxplot, donde se evidencian numerosos puntos extremos por encima del límite superior, coherente con el máximo de 12.000.000 y un coeficiente de variación alto (75,3%), lo que refleja **gran dispersión relativa**. Además, la media (665.201) es mayor que la mediana (550.000), lo cual reafirma el sesgo positivo.

Al aplicar la transformación logarítmica, la distribución se vuelve **más simétrica y concentrada**, reduciendo el efecto de los valores extremos y permitiendo una mejor visualización del comportamiento central de los datos. En escala logarítmica se aprecia con mayor claridad la estructura de la distribución y la variabilidad real entre los hogares, facilitando análisis posteriores como modelamiento estadístico o comparación entre

grupos. En conclusión, la transformación log mejora la interpretabilidad de una variable monetaria con alta asimetría y presencia de valores extremos, como es el caso del arriendo.

- Cálculo de los estimadores

Estimador	Estimadores Puntuales		Estimadores por Intervalo	
	Analogía	Máxima Verosimilitud	Límite Inferior	Límite Superior
(Media o Proporción)	665.200,8	665.200,8	659.445,9	670.955,7
Comentario	La media muestral es un estimador puntual de la media poblacional.	Asumiendo un modelo normal, el estimador de máxima verosimilitud coincide con la media muestral.	Corresponde al límite inferior del intervalo de confianza del 95% para la media	Corresponde al límite superior del intervalo de confianza del 95% para la media.

Evaluación del estimador:


Insensgamiento

Media	Mediana	Sesgo
665.201	550.000	La distribución presenta sesgo positivo

Comentario:

La diferencia entre la media (665.201) y la mediana (550.000) indica una distribución con sesgo positivo, causada por valores altos de arriendo que incrementan la media, mientras que la mediana se mantiene más estable.

Consistencia



Comentario:

Como se ve en la gráfica tanto la media como la mediana son consistentes aun así la media se ve más afectada al inicio esto debido a los valores extremos aun así mientras aumenta la cantidad de hogares esta se estabiliza mientras que la mediana se estabiliza más rápido.

Eficiencia

Medida	Valor
Media	8.63×10^6
Mediana	5.60×10^6

Comentario:

Para calcular la eficiencia debemos calcular la varianza de la distribución muestral, en este caso mediante bootstrap se obtuvieron los resultados de la tabla anterior de esto identificamos que la mediana presenta menor variabilidad y se concluye que es más eficiente para estos datos esto es coherente con la forma de la distribución que muestra asimetría y valores extremos muy altos lo que afecta más a la media y aumenta su dispersión como estimador.

Sintaxis empleada con esta variable:

```
arriendo_agosto <- read_delim("Agosto 2025/CSV/Datos del hogar y la vivienda.CSV",
                              delim = ";", escape_double = FALSE, trim_ws = TRUE)
```

```
arriendo_septiembre <- read_delim("Septiembre 2025/CSV/Datos del hogar y la
vivienda.CSV",
                                  delim = ";", escape_double = FALSE, trim_ws = TRUE)
```

```
arriendo_octubre <- read_delim("Octubre 2025/CSV/Datos del hogar y la vivienda.CSV",
                               delim = ";", escape_double = FALSE, trim_ws = TRUE)
```

```

arriendo <- bind_rows(
  arriendo_agosto %>% mutate(MES = as.character(MES)),
  arriendo_septiembre %>% mutate(MES = as.character(MES)),
  arriendo_octubre %>% mutate(MES = as.character(MES))
)

```

```

conteo_pago <- arriendo %>%
  group_by(DIRECTORIO) %>%
  summarise(
    tiene_arriendo_reportado = any(!is.na(P5140) & P5140 > 0),
    .groups = "drop"
  ) %>%
  count(tiene_arriendo_reportado) %>%
  mutate(
    Categoria = if_else(tiene_arriendo_reportado,
      "Sí pagan arriendo (reportan valor > 0)",
      "No pagan arriendo / no reportan valor"),
    porcentaje = round(n / sum(n) * 100, 1),
    etiqueta = paste0(n, " hogares (", porcentaje, "%)")
  )

```

```

resumen_arriendo <- arriendo %>%
  group_by(DIRECTORIO) %>%
  summarise(
    valor_arriendo = first(P5140[!is.na(P5140) & P5140 > 0]),
    .groups = "drop"
  ) %>%
  filter(!is.na(valor_arriendo))

```

```

resumen_limpio <- resumen_arriendo %>%
  filter(
    valor_arriendo >= 180000,
    valor_arriendo <= 12000000
  )

```

```

tabla_estadisticas <- resumen_limpio %>%
  summarise(
    `Número de hogares` = n(),
    Mínimo = min(valor_arriendo),
    Máximo = max(valor_arriendo),
    Promedio = mean(valor_arriendo),
    Mediana = median(valor_arriendo),
    Moda = as.numeric(names(sort(table(valor_arriendo), decreasing =
TRUE)[1])),
    Rango = max(valor_arriendo) - min(valor_arriendo),
    `Desviación estándar` = sd(valor_arriendo),
    `Coef. de variación (%)` = (sd(valor_arriendo) / mean(valor_arriendo)) * 100
  ) %>%

```

```

mutate(
  across(c(Mínimo, Máximo, Promedio, Mediana, Moda, Rango, `Desviación estándar`),
    ~ dollar(., prefix = "$", big.mark = ".", decimal.mark = ",", accuracy = 1)),
  `Coef. de variación (%)` = sprintf("%.1f%%", `Coef. de variación (%)`),
  `Número de hogares` = number(`Número de hogares`, big.mark = ".")
) %>%
pivot_longer(everything(), names_to = "Estadístico", values_to = "Valor") %>%
mutate(
  Estadístico = factor(Estadístico, levels = c(
    "Número de hogares", "Mínimo", "Máximo", "Promedio", "Mediana",
    "Moda", "Rango", "Desviación estándar", "Coef. de variación (%)")
  ))
) %>%
arrange(Estadístico)

print(tabla_estadisticas)

```


Ingresos_hogar

- *Análisis Descriptivo*

Descriptivos Básicos


	Medida	Valor
1	Número de hogares	59.104
2	Mínimo	0
3	Máximo	107.400.000
4	Media	2.711.475
5	Mediana	1.800.000
6	Moda	1.423.500
7	Rango	107.400.000
8	Desviación estándar	3332052
9	Coefficiente de variación	1.2288


Comentarios:

Los datos obtenidos en la tabla muestran que el ingreso mensual por hogar tiene una dispersión alta. Aunque el valor promedio del ingreso es de 2.711.475, la mediana es menor (1.800.000) lo que indica que existen hogares con ingresos muy altos que elevan el valor de la media por otro lado tenemos el valor mínimo de 0 que refleja la existencia de hogares sin ingresos mensuales mientras que el máximo es de 107.400.000 algo que evidencia una fuerte desigualdad y esto se nos confirma con la desviación estándar elevada y el coeficiente de variación de 1.23 esto indica que los ingresos varían más que el promedio mismo.

Análisis Gráfico

Histograma del ingreso mensual por hogar





Comentarios:

Como podemos ver en el histograma y en el boxplot el ingreso mensual por hogar la mayoría de familias se encuentran en los niveles bajos de ingresos mientras que algunos están en ingresos muy elevados. El histograma muestra alta frecuencia en los primeros intervalos y una disminución progresiva a medida que se aumenta el ingreso esto indica una distribución asimétrica positiva además esto se refuerza en el boxplot en donde la caja se encuentra en los valores mínimos además de aparece varios valores atípicos en las zonas de más ingresos. En conjunto estas gráficas nos permiten concluir que se presenta una distribución desigual, con alta variabilidad y una influencia de los valores extremos en las medidas de tendencia central.

- Cálculo de los estimadores

Estimador	Estimadores Puntuales		Estimadores por Intervalo	
	Analogía	Máxima Verosimilitud	Límite Inferior	Límite Superior
(Media o Proporción)	2.711.475	2.711.475	2.684.609	2.738.341
Comentario	La media muestral se utiliza como estimación directa de la media poblacional del ingreso mensual por hogar, ya que representa el promedio de los datos observados en la muestra.	Bajo el supuesto de una distribución normal, la media muestral es el estimador de máxima verosimilitud, por lo que coincide con el estimador obtenido por analogía.	Representa el valor mínimo del intervalo de confianza al 95%, indicando el menor ingreso promedio poblacional compatible con los datos observados.	Corresponde al valor máximo del intervalo de confianza al 95%, señalando el mayor ingreso promedio poblacional posible según la información muestral.


- Evaluación del estimador:

Inssegamiento

Media	Mediana	Sesgo
2.711.475	1.800.000	Sesgo positivo(cola a la derecha)

Comentario:

Consistencia



Comentario:

la gráfica muestra la evolución de la media y la mediana por hogar en esta se puede observar que ambas medidas presentan fuertes variaciones al inicio, cuando el tamaño de la muestra es pequeño pero a medida que este aumenta tanto la media como la mediana se estabilizan y tienden a valores constantes evidenciando que ambos estimadores son consistentes. La mediana presenta una convergencia más rápida lo cual es coherente con la presencia de valores extremos tan altos y con la asimetría positiva previamente observada en la distribución de los ingresos.

Eficiencia

Medida	Valor
Media	178.782.76
Mediana	9

Comentario:

La varianza de la distribución muestral obtenida mediante bootstrap muestra que la media presenta una variabilidad de 178.782.769, mientras que la mediana presenta varianza de 0. En el remuestreo la mediana no presentó cambios, evidenciando una alta estabilidad como estimador y por ende se concluye que la mediana es más eficiente para estos datos lo cual se relaciona con la asimetría positiva y la presencia de valores extremos que afecta más a la media.

Sintaxis empleada con esta variable:

```
#### Importación de Datos  
library(readr)
```

```

# Datos generales
sueldo_agosto <- read_delim("Agosto 2025/CSV/ocupados.CSV",
                           delim = ";", escape_double = FALSE, trim_ws = TRUE)
sueldo_septiembre <- read_delim("Septiembre 2025/CSV/ocupados.CSV",
                                delim = ";", escape_double = FALSE, trim_ws = TRUE)
sueldo_octubre <- read_delim("Octubre 2025/CSV/ocupados.CSV",
                             delim = ";", escape_double = FALSE, trim_ws = TRUE)

#### Procesamiento

sueldo_agosto <- sueldo_agosto %>%
  mutate(across(everything(), as.character))

sueldo_septiembre <- sueldo_septiembre %>%
  mutate(across(everything(), as.character))

sueldo_octubre <- sueldo_octubre %>%
  mutate(across(everything(), as.character))

library(dplyr)

sueldo_general <- bind_rows(
  sueldo_octubre,
  sueldo_agosto,
  sueldo_septiembre
)

sueldo_general <- sueldo_general %>%
  mutate(INGLABO = as.numeric(INGLABO))

moda <- function(x) {
  x <- x[!is.na(x)]
  if (length(x) == 0) return(NA)
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}

ingreso_hogar <- sueldo_general %>%
  mutate(INGLABO = as.numeric(INGLABO)) %>%
  filter(!is.na(INGLABO)) %>%
  group_by(DIRECTORIO) %>%
  summarise(
    ingreso_hogar = sum(INGLABO),
    personas_con_ingreso = n(),
    .groups = "drop"
  )

ingresos_generales <- ingreso_hogar %>%
  summarise(
    minimo = min(ingreso_hogar),
    maximo = max(ingreso_hogar),

```

```

media = mean(ingreso_hogar),
mediana = median(ingreso_hogar),
moda = moda(ingreso_hogar),
numero_hogares = n(),
rango = max(ingreso_hogar) - min(ingreso_hogar),
desviacion_estandar = sd(ingreso_hogar),
coeficiente_variacion = ifelse(
  is.na(mean(ingreso_hogar)) | mean(ingreso_hogar) == 0,
  NA,
  sd(ingreso_hogar) / mean(ingreso_hogar)
)
)

print(as.data.frame(ingresos_generales))

hist(
  ingreso_hogar$ingreso_hogar,
  breaks = 50,
  main = "Histograma del ingreso mensual por hogar",
  xlab = "Ingreso mensual del hogar",
  ylab = "Frecuencia"
)
boxplot(
  ingreso_hogar$ingreso_hogar,
  main = "Boxplot del ingreso mensual por hogar",
  ylab = "Ingreso mensual del hogar"
)

ingresos <- ingreso_hogar$ingreso_hogar

media_acumulada <- cumsum(ingresos) / seq_along(ingresos)

mediana_acumulada <- sapply(1:length(ingresos), function(i) {
  median(ingresos[1:i])
})

plot(
  media_acumulada,
  type = "l",
  xlab = "Número de hogares",
  ylab = "Valor estimado",
  main = "Consistencia de la media y la mediana"
)

lines(mediana_acumulada, lty = 2)

legend(
  "topright",
  legend = c("Media acumulada", "Mediana acumulada"),
  lty = c(1, 2)
)

```

```
set.seed(123)

ingresos <- ingreso_hogar$ingreso_hogar
B <- 1000 # número de remuestras

media_boot <- numeric(B)
mediana_boot <- numeric(B)

for (i in 1:B) {
  muestra <- sample(ingresos, replace = TRUE)
  media_boot[i] <- mean(muestra)
  mediana_boot[i] <- median(muestra)
}

var_media <- var(media_boot)
var_mediana <- var(mediana_boot)

var_media
var_mediana
```

promedio_edad

- Análisis Descriptivo

Descriptivos Básicos

	Medida	Valor
1	Número de hogares	73381
2	Mínimo	7.33
3	Máximo	99
4	Media	40.78
5	Mediana	37
6	Moda	30
7	Rango	91.67
8	Desviación estándar	18.14
9	Coefficiente de variación	0.44


Comentarios:

Los datos obtenidos en la tabla muestran que la edad promedio por hogar presenta una dispersión moderada. El valor promedio es de 40.78 años, mientras que la mediana es 37 años, lo que indica una ligera asimetría positiva, es decir, existen algunos hogares con promedios de edad más altos que elevan el valor de la media.

El valor mínimo registrado es 7.33 años, lo que sugiere la existencia de hogares compuestos principalmente por personas jóvenes, mientras que el valor máximo es 99 años, evidenciando hogares con presencia predominante de adultos mayores.

El rango de 91.67 años muestra una diferencia considerable entre los hogares más jóvenes y los más envejecidos. Sin embargo, la desviación estándar de 18.14 y el coeficiente de variación de 0.44 indican que, aunque existe variabilidad en la composición etaria de los hogares, esta no es excesiva, manteniéndose dentro de un nivel moderado de dispersión.

Análisis Gráfico




El histograma del promedio de edad por hogar muestra una distribución con asimetría positiva (cola hacia la derecha), lo cual puede llegar a ser coherente con el análisis anterior donde la media (40.78) es mayor que la mediana (37).

Se observa que la mayor concentración de hogares se encuentra aproximadamente entre los 25 y 45 años, lo que muestra que la mayoría de los hogares presentan un promedio de edad correspondiente a población adulta joven y adulta media.

A medida que aumenta el promedio de edad, la frecuencia disminuye progresivamente, lo que nos da a entender que los hogares con promedios muy elevados (superiores a 70 años) son menos frecuentes.

La forma de la distribución sugiere una variabilidad moderada, sin presencia de valores extremadamente atípicos dominantes, lo cual es consistente con el coeficiente de variación de 0.44 obtenido previamente.



Comentarios:

El boxplot del promedio de edad por hogar muestra que la mediana se encuentra alrededor de los 37 años, lo que muestra que la mitad de los hogares tienen un promedio de edad menor a este valor y la otra mitad mayor.

Se observa que la distribución presenta una ligera asimetría positiva (hacia la derecha), ya que existen algunos valores atípicos en la parte superior del gráfico, correspondientes a hogares con promedios de edad elevados (cercanos a 100 años).

El rango intercuartílico muestra que la mayor concentración de hogares se encuentra aproximadamente entre los 25 y 55 años de promedio, lo que indica que la mayoría de los hogares tienen una estructura etaria moderada.

En general, aunque existen valores extremos altos, la distribución del promedio de edad por hogar se concentra principalmente en edades adultas, con una dispersión moderada.

- **Cálculo de los estimadores**

Estimador	Estimadores Puntuales		Estimadores por Intervalo	
	Analogía	Máxima Verosimilitud	Límite Inferior	Límite Superior
(Media o Proporción)	40.78236	40.78236	40.6511	40.91361
Comentario	Corresponde a la media muestral del	Coincide con la media muestral y es el	Valor mínimo que es esperado para	Valor máximo para la media poblacional con

	promedio de edad por hogar	estimador más eficiente bajo normalidad	la media poblacional con el nivel de confianza establecido con anterioridad	el nivel de confianza ya establecido anteriormente
--	----------------------------	---	---	--

- **Evaluación del estimador:**

Insensgamiento


Media	Mediana	Sesgo
40.78	37	Sesgo positivo (derecha)

Comentario:

La media (40.78) es mayor que la mediana (37), lo que indica sesgo positivo. Esto significa que existen valores altos que desplazan la distribución hacia la derecha, aunque la diferencia no es muy grande, por lo que el sesgo es moderado.

Consistencia

Consistencia de la media y la mediana



Comentario: En la gráfica se puede ver que al inicio la media y la mediana cambian mucho porque todavía hay pocos hogares. Eso hace que los valores suban y bajen bastante. Pero a medida que se van incluyendo más hogares, las dos líneas se empiezan a estabilizar y casi no cambian. La media se mantiene alrededor de 40 y la mediana alrededor de 37. Esto muestra que los estimadores son consistentes, ya que cuando aumenta la cantidad de datos los resultados se vuelven más estables y confiables.

Eficiencia

Medida	Valor
Media	0.00430494 4
Mediana	0.01887598

Comentario: En la tabla de eficiencia se observa que la varianza de la media (0.0043) es menor que la varianza de la mediana (0.0189). Esto significa que la media es más eficiente, ya que presenta menor variabilidad entre las muestras bootstrap. En otras palabras, la media cambia menos que la mediana cuando se toman diferentes muestras, por lo que es un estimador más preciso para estos datos.

Sintaxis empleada con esta variable:

Importación de Datos

```
library(readr)
```

Datos generales

```
edad_agosto <- read_delim("Agosto 2025/CSV/Características generales, seguridad  
social en salud y educación.CSV",
```

```
  delim = ";", escape_double = FALSE, trim_ws = TRUE)
```

```
edad_septiembre <- read_delim("Septiembre 2025/CSV/Características generales,  
seguridad social en salud y educación.CSV",
```

```
  delim = ";", escape_double = FALSE, trim_ws = TRUE)
```

```
edad_octubre <- read_delim("Octubre 2025/CSV/Características generales, seguridad  
social en salud y educación.CSV",
```

```
  delim = ";", escape_double = FALSE, trim_ws = TRUE)
```

Procesamiento

```
library(dplyr)
```

```
edad_agosto <- edad_agosto %>%
```

```
  mutate(across(everything(), as.character))
```

```
edad_septiembre <- edad_septiembre %>%
```

```
  mutate(across(everything(), as.character))
```

```
edad_octubre <- edad_octubre %>%
```

```
mutate(across(everything(), as.character))
```

```
edad_general <- bind_rows(  
  edad_octubre,  
  edad_agosto,  
  edad_septiembre  
)
```

```
edad_general <- edad_general %>%  
  mutate(P6040 = as.numeric(P6040))
```

```
moda <- function(x) {  
  x <- x[!is.na(x)]  
  if (length(x) == 0) return(NA)  
  ux <- unique(x)  
  ux[which.max(tabulate(match(x, ux)))]  
}
```

```
edad_hogar <- edad_general %>%  
  mutate(P6040 = as.numeric(P6040)) %>%  
  filter(!is.na(P6040)) %>%  
  group_by(DIRECTORIO) %>%  
  summarise(  
    edad_hogar = mean(P6040),  
    personas_en_hogar = n(),  
    .groups = "drop"  
  )
```

```
edades_generales <- edad_hogar %>%
```

```

summarise(
  minimo = min(edad_hogar),
  maximo = max(edad_hogar),
  media = mean(edad_hogar),
  mediana = median(edad_hogar),
  moda = moda(edad_hogar),
  numero_hogares = n(),
  rango = max(edad_hogar) - min(edad_hogar),
  desviacion_estandar = sd(edad_hogar),
  coeficiente_variacion = ifelse(
    is.na(mean(edad_hogar)) | mean(edad_hogar) == 0,
    NA,
    sd(edad_hogar) / mean(edad_hogar)
  )
)

```

```

print(as.data.frame(edades_generales))

```

```

hist(
  edad_hogar$edad_hogar,
  breaks = 50,
  main = "Histograma del promedio de edad por hogar",
  xlab = "Promedio de edad del hogar",
  ylab = "Frecuencia"
)

```

```

boxplot(
  edad_hogar$edad_hogar,
  main = "Boxplot del promedio de edad por hogar",
  ylab = "Promedio de edad del hogar"
)

```

```
)
```

```
edades <- edad_hogar$edad_hogar
```

```
media_acumulada <- cumsum(edades) / seq_along(edades)
```

```
mediana_acumulada <- sapply(1:length(edades), function(i) {  
  median(edades[1:i])  
})
```

```
plot(  
  media_acumulada,  
  type = "l",  
  xlab = "Número de hogares",  
  ylab = "Valor estimado",  
  main = "Consistencia de la media y la mediana"  
)
```

```
lines(mediana_acumulada, lty = 2)
```

```
legend(  
  "topright",  
  legend = c("Media acumulada", "Mediana acumulada"),  
  lty = c(1, 2)  
)
```

```
set.seed(123)
```

```
edades <- edad_hogar$edad_hogar
```

```
B <- 1000
```

```
media_boot <- numeric(B)
mediana_boot <- numeric(B)
```

```
for (i in 1:B) {
  muestra <- sample(edades, replace = TRUE)
  media_boot[i] <- mean(muestra)
  mediana_boot[i] <- median(muestra)
}
```

```
var_media <- var(media_boot)
var_mediana <- var(mediana_boot)
```

```
var_media
var_mediana
```

```
# Vector de datos
x <- edad_hogar$edad_hogar
```

```
# Tamaño de muestra
n <- length(x)
```

```
# Media (Estimador puntual)
media <- mean(x)
```

```
# Desviación estándar
s <- sd(x)
```

```
# Error estándar
error_estandar <- s / sqrt(n)
```

```
# Nivel de confianza 95%
```

```
z <- 1.96
```

```
# Intervalo de confianza
```

```
limite_inferior <- media - z * error_estandar
```

```
limite_superior <- media + z * error_estandar
```

```
# Mostrar resultados
```

```
resultados <- data.frame(
```

```
  Estimador = "Media",
```

```
  Analogia = media,
```

```
  Maxima_Verosimilitud = media,
```

```
  Limite_Inferior = limite_inferior,
```

```
  Limite_Superior = limite_superior
```

```
)
```

```
print(resultados)
```

```
media <- mean(edad_hogar$edad_hogar)
```

```
mediana <- median(edad_hogar$edad_hogar)
```

```
sesgo <- ifelse(media > mediana,
```

```
  "Sesgo positivo (derecha)",
```

```
  ifelse(media < mediana,
```

```
    "Sesgo negativo (izquierda)",
```

```
    "Distribución simétrica"))
```

```
data.frame(Media = round(media,2),
```

```
  Mediana = round(mediana,2),
```


Sesgo = sesgo)

Variable 4
Tipo _hogar

Código	Tipo de hogar	Frecuencia	Frecuencia relativa	Porcentaje (%)
1	Casa	39.684	0.5410	54.10%
2	Apartamento	31.993	0.4360	43.60%
3	Cuarto(s)	1.358	0.0185	1.85%
5	Vivienda indígena	331	0.00451	0.45%
6	Otra vivienda (carpa, vagón, embarcación, cueva, refugio natural, etc.)	15	0.000204	0.02%
Total		73.381	1.0000	100%

Tabla: Distribución de la variable tipo _hogar

- Análisis Descriptivo

Descriptivos Básicos

Medida	Casa(1)	No casa(0)
Frecuencia absoluta	39684	33697
Frecuencia relativa	0.541	0.459
Porcentaje	54.1	45.9
Moda	casa	casa
Media (proporción)	0.541	0.541
Varianza	0.248	0.248
Desviación estándar	0.498	0.498
Tamaño de muestra	73381	73381

Intervalo de confianza 95%	(0.544)-(0.537)	(0.537)-(0.544)
---------------------------------------	-----------------	-----------------

Comentarios: **Tratamiento y análisis de la variable cualitativa tipo_hogar**

En el presente análisis, se trabajó con la variable **cualitativa nominal tipo_hogar**, correspondiente al tipo de vivienda de cada hogar, con categorías como Casa, Apartamento, Cuarto(s), Vivienda indígena y otras formas de vivienda. Dado que esta variable no posee un orden natural ni un valor numérico intrínseco, no es posible realizar directamente operaciones estadísticas como promedio, varianza o inferencia paramétrica sobre sus valores originales.

1. Importación y consolidación de los datos

Se importaron los archivos correspondientes a los meses de agosto, septiembre y octubre de 2025 utilizando la función `read_delim` de R. Posteriormente, se consolidaron en un único conjunto de datos mediante la función `bind_rows`, garantizando que se trabajara con la totalidad de los hogares registrados durante el período de estudio.

2. Limpieza y preparación de los datos

Se eliminaron los registros con valores faltantes o vacíos en la variable `P4005` (tipo de hogar), asegurando que únicamente se considerarán observaciones completas y válidas. Además, se creó un registro único por hogar mediante la agrupación por `DIRECTORIO`, tomando el primer valor no nulo de la variable `tipo_hogar` para cada hogar. Esto permitió evitar duplicidad y trabajar con un conjunto de datos homogéneo.

3. Análisis inicial de frecuencias

Antes de la transformación, se calculó la **frecuencia absoluta, relativa y porcentaje** de cada categoría de vivienda, con el fin de obtener un panorama general de la distribución de los tipos de hogar en la muestra. Asimismo, se asignaron descripciones significativas a los códigos numéricos, facilitando la interpretación de los resultados.

4. Transformación de la variable cualitativa en variable binaria

Para permitir el cálculo de medidas estadísticas como media, varianza y estimación de intervalos de confianza, se transformó la variable cualitativa en una **variable binaria o dummy** (`tipo_hogar_bin`), definida de la siguiente manera:

- **1** si el hogar es **Casa**
- **0** para todas las demás categorías

Esta transformación convierte la variable en un **experimento de Bernoulli**, en el que cada observación representa un éxito (Casa) o un fracaso (No casa).

5. Tabla de frecuencias binaria y medidas estadísticas

Con la variable binaria se construyó una tabla de frecuencias que incluye la **frecuencia absoluta, frecuencia relativa y porcentaje** para cada categoría (Casa vs No casa). A partir de esta variable, se calcularon las siguientes medidas estadísticas:

- **Media (proporción):** representa la proporción de hogares que son Casas dentro del total de la muestra.
- **Varianza y desviación estándar:** calculadas bajo el modelo Bernoulli, reflejando la dispersión de la variable binaria.
- **Moda:** categoría con mayor frecuencia en la muestra.
- **Intervalo de confianza al 95%:** estimado para la proporción de Casas mediante la fórmula clásica de error estándar de una proporción:

6. Validación mediante bootstrap


Para robustecer la estimación de la proporción de Casas y su intervalo de confianza, se implementó un procedimiento de **bootstrap con 1000 repeticiones**, muestreando con reemplazo la variable binaria y calculando la proporción en cada muestra. Se obtuvieron los percentiles 2.5% y 97.5% de las proporciones generadas, construyendo así un intervalo de confianza empírico al 95%, sin asumir normalidad de la muestra.

Conclusión

Este procedimiento permitió convertir una variable cualitativa nominal en una variable cuantitativa binaria, facilitando la aplicación de métodos estadísticos de inferencia. La combinación de la transformación binaria y el análisis bootstrap garantiza estimaciones confiables de la proporción de hogares tipo Casa, proporcionando información estadística robusta sobre la distribución de tipos de vivienda en la muestra analizada.

Análisis Gráfico

Proporción de tipo de hogar



Comentarios: Estos gráficos permiten visualizar de manera inmediata que la mayoría de los hogares son **Casa**, seguida por **Apartamento**, y que las demás categorías son minoritarias.

- Cálculo de los estimadores

Estimador	Estimadores Puntuales		Estimadores por Intervalo	
	Analogía	Máxima Verosimilitud	Límite Inferior	Límite Superior
(Media o Proporción)	0.541	Sí, $\hat{p}$ es MV para Bernoulli	0.537	0.544
Comentario	Indica que aproximadamente el 54.1% de los hogares son casas.	La proporción muestral $\hat{p}$ es el estimador MV, y los límites inferior y superior representan los extremos del IC de confianza para la proporción.	Representa el valor más bajo plausible de la proporción de hogares tipo Casa con un 95% de confianza.	Representa el valor más alto plausible de la proporción de hogares tipo Casa con un 95% de confianza.

- Evaluación del estimador:


Insesgamiento

Media	Mediana	Sesgo
0.541	0	0

Comentario:

El estimador de proporción $\hat{p}$ es insesgado, ya que la media de la muestra coincide con la proporción real de hogares tipo Casa en la población. La mediana de la variable binaria indica que más del 50% de los hogares son Casas (1), reflejando que la distribución está centrada alrededor del valor más frecuente. En este caso, como la proporción de Casas es ligeramente mayor que 50%, la mediana refleja correctamente el punto central de la muestra. El sesgo se calcula como la diferencia entre la media del estimador y el verdadero valor poblacional; dado que $\hat{p}$ es insesgado, el sesgo es 0, lo que confirma que el estimador es confiable y no subestima ni sobreestima la proporción real de Casas.

Consistencia



Comentario:

La gráfica combinada muestra claramente la distribución de hogares según el tipo de vivienda. El **gráfico de barras** evidencia que la mayoría de los hogares son Casas, con una frecuencia de 39,684, mientras que los hogares que no son Casas suman 33,697. Por otro lado, el **gráfico de pastel** permite visualizar la proporción relativa de cada categoría: aproximadamente el 54.1% de los hogares son Casas y el 45.9% no lo son. Esta representación conjunta facilita la interpretación, mostrando tanto la magnitud absoluta como la proporción relativa, lo que permite identificar rápidamente la categoría predominante y entender la distribución de la variable **tipo_hogar** en la muestra.

Eficiencia

Medida	Valor
Media	0.248
Mediana	0.248

Comentario:

La varianza del estimador de la **media** (proporción de Casas) es 0.248, lo que indica la dispersión de la variable binaria alrededor de la media y confirma que el estimador es eficiente. La varianza de la **mediana** también es 0.248, prácticamente igual a la de la media. Esto se debe a que la variable **tipo_hogar_bin** solo toma dos valores (0 = No casa, 1 = Casa) y la muestra es muy grande, por lo que la mediana se sitúa cerca de la media en términos de dispersión. En variables binarias con muestras grandes, la mediana y la media reflejan de manera muy similar la distribución de los datos, y por eso sus varianzas son prácticamente iguales. Esto confirma que el estimador de proporción $\hat{p}$ es eficiente, insesgado y confiable.

Sintaxis empleada con esta variable:

```
# --- Librerías ---
library(readr)
library(dplyr)
library(ggplot2)
library(gridExtra)

# --- Importación de datos ---
tipo_hogar_agosto <- read_delim("Agosto 2025/CSV/Datos del hogar y la vivienda.CSV",
                                delim = ";", escape_double = FALSE, trim_ws = TRUE)
tipo_hogar_septiembre <- read_delim("Septiembre 2025/CSV/Datos del hogar y la
vivienda.CSV",
                                delim = ";", escape_double = FALSE, trim_ws = TRUE)
tipo_hogar_octubre <- read_delim("Octubre 2025/CSV/Datos del hogar y la
vivienda.CSV",
                                delim = ";", escape_double = FALSE, trim_ws = TRUE)

# --- Consolidación y limpieza ---
tipo_hogar_agosto$MES <- as.character(tipo_hogar_agosto$MES)
tipo_hogar_septiembre$MES <- as.character(tipo_hogar_septiembre$MES)
tipo_hogar_octubre$MES <- as.character(tipo_hogar_octubre$MES)

TIPO_HOGAR <- bind_rows(tipo_hogar_agosto, tipo_hogar_septiembre,
                        tipo_hogar_octubre) %>%
  filter(!is.na(P4005) & P4005 != "")

# --- Registro único por hogar ---
tipo_hogar_uniq <- TIPO_HOGAR %>%
  group_by(DIRECTORIO) %>%
  summarise(tipo_hogar = first(na.omit(P4005)), .groups = "drop")

# --- Transformación a variable binaria ---
tipo_hogar_uniq <- tipo_hogar_uniq %>%
  mutate(tipo_hogar_num = as.numeric(as.character(tipo_hogar)),
         tipo_hogar_bin = ifelse(tipo_hogar_num == 1, 1, 0))

# --- Tabla de frecuencias binarias ---
tabla_binaria <- tipo_hogar_uniq %>%
  group_by(tipo_hogar_bin) %>%
  summarise(Frecuencia = n(), .groups = "drop") %>%
  mutate(Categoria = ifelse(tipo_hogar_bin == 1, "Casa", "No casa"),
         Frecuencia_relativa = Frecuencia / sum(Frecuencia),
         Porcentaje = Frecuencia_relativa * 100) %>%
  select(Categoria, Frecuencia, Frecuencia_relativa, Porcentaje)

print(tabla_binaria)

# --- Medidas estadísticas ---
F_Casa <- tabla_binaria$Frecuencia[tabla_binaria$Categoria == "Casa"]
```

```

F_NoCasa <- tabla_binaria$Frecuencia[tabla_binaria$Categoria == "No casa"]
n <- F_Casa + F_NoCasa
p_hat <- F_Casa / n
varianza <- p_hat * (1 - p_hat)
desviacion <- sqrt(varianza)
error_estandar <- sqrt(p_hat * (1 - p_hat) / n)
z <- 1.96
IC_inf <- p_hat - z * error_estandar
IC_sup <- p_hat + z * error_estandar
moda <- ifelse(F_Casa > F_NoCasa, "Casa", "No casa")

# --- Tabla final ---
tabla_final <- data.frame(
  Medida = c("Frecuencia absoluta", "Frecuencia relativa", "Porcentaje", "Moda",
    "Media (proporción)", "Varianza", "Desviación estándar", "Tamaño de muestra",
    "Intervalo de confianza 95%"),
  Casa = c(F_Casa, round(F_Casa/n, 3), round((F_Casa/n)*100, 1),
    moda, round(p_hat, 3), round(varianza, 3), round(desviacion, 3), n,
    paste0(round(IC_inf, 3), " – ", round(IC_sup, 3))),
  No_casa = c(F_NoCasa, round(F_NoCasa/n, 3), round((F_NoCasa/n)*100, 1),
    moda, round(p_hat, 3), round(varianza, 3), round(desviacion, 3), n,
    paste0(round(IC_inf, 3), " – ", round(IC_sup, 3)))
)

print(tabla_final)

# --- Bootstrap para validación del IC ---
set.seed(123)
vector_hogar <- tipo_hogar_uniq$tipo_hogar_bin
n_boot <- 1000
bootstrap_means <- numeric(n_boot)

for(i in 1:n_boot){
  sample_i <- sample(vector_hogar, size = length(vector_hogar), replace = TRUE)
  bootstrap_means[i] <- mean(sample_i)
}

summary(bootstrap_means)
hist(bootstrap_means, main = "Bootstrap de proporción tipo_hogar == 1", xlab =
"Proporción")
IC_boot <- quantile(bootstrap_means, probs = c(0.025, 0.975))
print(IC_boot)

# --- Gráfico de barras ---
g_barras <- ggplot(tabla_binaria, aes(x = Categoria, y = Frecuencia, fill = Categoria)) +
  geom_bar(stat = "identity") +
  labs(title = "Distribución de tipo de hogar", x = "Tipo de hogar", y = "Frecuencia") +
  scale_fill_manual(values = c("Casa" = "steelblue", "No casa" = "tomato")) +
  theme_minimal()

# --- Gráfico de pastel ---

```



```

g_pastel <- ggplot(tabla_binaria, aes(x = "", y = Porcentaje, fill = Categoria)) +
  geom_col() +
  coord_polar(theta = "y") +
  geom_text(aes(label = paste0(round(Porcentaje, 1), "%")),
            position = position_stack(vjust = 0.5)) +
  labs(title = "Proporción de tipo de hogar") +
  scale_fill_manual(values = c("Casa" = "steelblue", "No casa" = "tomato")) +
  theme_void()

# --- Combinar gráficos ---
grid.arrange(g_barras, g_pastel, ncol = 2)

```